

Bigdata 101

HDFS Komutları ve Admin operasyonları

Veysel Yüksel



Table of Contents

01

HDFS Komutları

02

HDFS Admin Komutları

03

HDFS Web UI

04

HDFS Snapshot ve Rebalance

05

HDFS User Yetkilendirme

06

Soru Cevap

HDFS Komutları

HDFS dosya sisteminin yönetimi linux işletim sistemi üzerinden komutlarla yapılır. **Hdfs dfs** komutu ile çalıştırılan komutlar linux directory yönetim komutlarına oldukça benzerdir.

hdfs dfs -ls / : Komutu sonda verilen dizinin altındaki dosya veya klasörleri listeler.

```
[hadoop@masternode01 sbin]$ hdfs dfs -ls /
```

```
Found 6 items
```

```
drwxr-xr-x - hadoop supergroup 0 2024-09-04 20:01 /input
drwxr-xr-x - hadoop supergroup 0 2024-09-06 18:27 /output
drwxr-xr-x - hadoop supergroup 0 2024-09-06 18:31 /output2
drwxr-xr-x - hadoop supergroup 0 2024-09-07 16:43 /output4
drwxr-xr-x - hadoop supergroup 0 2024-09-07 17:32 /output9
drwxr-xr-x - hadoop supergroup 0 2024-09-02 20:52 /tmp
```

HDFS Komutlar

hdfs dfs -mkdir HDFS'de yeni bir dizin oluşturur.

```
[hadoop@masternode01 sbin]$ hdfs dfs -mkdir /sampledirectory
```

```
[hadoop@masternode01 sbin]$ hdfs dfs -ls /
```

Found 7 items

drwxr-xr-x - hadoop supergroup	0	2024-09-04 20:01	/input
drwxr-xr-x - hadoop supergroup	0	2024-09-06 18:27	/output
drwxr-xr-x - hadoop supergroup	0	2024-09-06 18:31	/output2
drwxr-xr-x - hadoop supergroup	0	2024-09-07 16:43	/output4
drwxr-xr-x - hadoop supergroup	0	2024-09-07 17:32	/output9
drwxr-xr-x - hadoop supergroup	0	2024-09-07 19:53	/sampledirectory

HDFS Komutlar

hdfs dfs -rmdir /sampledirectory Boş bir dizini siler.

```
[hadoop@masternode01 ~]$ hdfs dfs -rmdir /sampledirectory
```

hdfs dfs -rm -r /directory/file Bir dizin altındaki dosyaları silmek için kullanılır.

```
[hadoop@masternode01 ~]$ hdfs dfs -ls /output
```

Found 2 items

```
-rw-r--r-- 1 hadoop supergroup    0 2024-09-06 18:27 /output/_SUCCESS
```

```
-rw-r--r-- 1 hadoop supergroup  94 2024-09-06 18:27 /output/part-r-00000
```

```
[hadoop@masternode01 ~]$ hdfs dfs -rm /output/part-r-00000
```

Deleted /output/part-r-00000

HDFS Komutlar

hdfs dfs -cp <source> <destination> Source'da yer alan dosyanın verilen destination dizine kopyalanmasını sağlar.

```
[hadoop@masternode01 ~]$ hdfs dfs -ls /input
```

Found 2 items

```
-rw-r--r-- 1 hadoop supergroup 83 2024-09-04 20:01 /input/example.txt
```

```
-rw-r--r-- 1 hadoop supergroup 69 2024-09-02 20:48 /input/input.txt
```

```
[hadoop@masternode01 ~]$ hdfs dfs -cp /input/example.txt /output
```

```
[hadoop@masternode01 ~]$ hdfs dfs -ls /output
```

Found 2 items

```
-rw-r--r-- 1 hadoop supergroup 0 2024-09-06 18:27 /output/_SUCCESS
```

```
-rw-r--r-- 1 hadoop supergroup 83 2024-09-08 10:53 /output/example.txt
```

HDFS Komutlar

hdfs dfs -mv <source> <destination> HDFS'deki bir dosya veya dizini taşır veya yeniden adlandırır.

```
[hadoop@masternode01 ~]$ hdfs dfs -mv /input/example.txt /input/example2.txt
```

```
[hadoop@masternode01 ~]$ hdfs dfs -ls /input
```

Found 2 items

```
-rw-r--r-- 1 hadoop supergroup 83 2024-09-04 20:01 /input/example2.txt
```

```
-rw-r--r-- 1 hadoop supergroup 69 2024-09-02 20:48 /input/input.txt
```

HDFS Komutlar

hdfs dfs -cat <path> HDFS'deki bir dosyanın içeriğini gösterir.

```
[hadoop@masternode01 ~]$ hdfs dfs -cat /input/input.txt
```

Hadoop is a framework

Hadoop is used for big data

Hadoop is scalable

HDFS Komutlar

hdfs dfs -get <hdfs_path> <local_path> HDFS'deki bir dosyayı yerel dosya sistemine indirir.

```
[hadoop@masternode01 ~]$ pwd
```

```
/home/hadoop
```

```
[hadoop@masternode01 ~]$ ls
```

```
input.txt
```

```
[hadoop@masternode01 ~]$ hdfs dfs -get /input/example2.txt /home/hadoop
```

```
[hadoop@masternode01 ~]$ ls -l
```

```
total 8
```

```
-rw-r--r--. 1 hadoop hadoop 83 Sep 8 11:00 example2.txt
```

```
-rw-rw-r--. 1 hadoop hadoop 69 Sep 2 20:47 input.txt
```

HDFS Komutlar

hdfs dfs -put <local_path> <hdfs_path> Yerel dosya sistemindeki bir dosyayı HDFS'e kopyalar.

```
[hadoop@masternode01 ~]$ touch "newsamplefile"
```

```
[hadoop@masternode01 ~]$ hdfs dfs -put /home/hadoop/newsamplefile /input
```

```
[hadoop@masternode01 ~]$ hdfs dfs -ls /input
```

Found 3 items

-rw-r--r--	1	hadoop	supergroup	83	2024-09-04 20:01	/input/example2.txt
-rw-r--r--	1	hadoop	supergroup	69	2024-09-02 20:48	/input/input.txt
-rw-r--r--	1	hadoop	supergroup	0	2024-09-08 11:02	/input/newsamplefile

HDFS Komutlar

hdfs dfs -du <path> Belirtilen dizindeki dosya ve dizinlerin disk kullanımını gösterir.

```
[hadoop@masternode01 ~]$ hdfs dfs -du /input
83 83 /input/example2.txt
69 69 /input/input.txt
0 0 /input/newsamplefile
```

HDFS Komutlar

hdfs dfs -df -h HDFS'deki dosya sisteminin genel kullanım durumunu gösterir.

```
[hadoop@masternode01 ~]$ hdfs dfs -df -h
```

Filesystem	Size	Used	Available	Use%
hdfs://masternode01:9000	39.6 G	6.7 M	26.6 G	0%

HDFS Komutlar

hdfs dfs -chmod <permissions> <path> HDFS'deki dosya veya dizinlerin izinlerini değiştirir.

```
[hadoop@masternode01 ~]$ hdfs dfs -chmod 777 /input/example2.txt
```

```
[hadoop@masternode01 ~]$ hdfs dfs -ls /input/example2.txt
```

```
-rwxrwxrwx 1 hadoop supergroup 83 2024-09-04 20:01 /input/example2.txt
```


HDFS Komutlar

hdfs dfs -chown <owner>:<group> <path> HDFS'deki dosya veya dizinlerin sahibi ve grubunu değiştirir.

```
[hadoop@masternode01 ~]$ hdfs dfs -chown hadoopnew:hadoopnew /input/example2.txt  
[hadoop@masternode01 ~]$ hdfs dfs -ls /input/example2.txt  
-rwxrwxrwx 1 hadoopnew hadoopnew 83 2024-09-04 20:01 /input/example2.txt
```

HDFS Komutlar

hdfs dfs -count <path> Belirtilen dizindeki dosya ve dizin sayısını ve toplam boyutunu gösterir.

```
hadoop@masternode01 ~]$ hdfs dfs -count /input
1    3    152 /input
```

HDFS Komutlar

`hdfs dfs -appendToFile <local-file> <hdfs-file>` local-file'da bulunan datayı, hdfs'te bulunan bir dosyanın sonuna eklemeyi sağlayan komuttur.

```
[hadoop@masternode01 ~]$ hdfs dfs -cat /input/input.txt
```

Hadoop is a framework

Hadoop is used for big data

Hadoop is scalable

```
[hadoop@masternode01 ~]$ echo "new data starts from here" >> newfile.txt
```

```
[hadoop@masternode01 ~]$ hdfs dfs -appendToFile newfile.txt /input/input.txt
```

```
[hadoop@masternode01 ~]$ hdfs dfs -cat /input/input.txt
```

Hadoop is a framework

Hadoop is used for big data

Hadoop is scalable

new data starts from here

HDFS Komutlar

hdfs dfs -help <command> Bu komut ile hdfs komutları ile ilgili bilgi alınabilir.
Örneğin ls komutu hakkında bilgi almak için;

```
[hadoop@masternode01 ~]$ hdfs dfs -help ls
```

HDFS User Oluşturma

HDFS Directory ve User'lar

HDFS dosya sistemi linux işletim sisteminde olduğu gibi hiyerarşik yapıdadır ve HDFS'de her şey kök dizin (/) altında başlar. Tüm dosyalar ve dizinler bu kök dizin içinde organize edilir.

Directory'ler dosyaları organize etmek için kullanılır ve bir dizin diğer dizinlerin ve dosyaları içerebilir.

Linux işletim sistemi üzerinde yaratılan farklı user'lar da HDFS'i kullanabilir. Şimdiye kadar sadece hadoop user ve supergroup üzerinden komutları çalıştırdık.

Farklı user'lar için hdfs üzerinde /users altında user adı ile aynı isimde bir directory oluşturulur. Ve user'ların home dizinleri bu directory olur.

HDFS User Oluşturma

Linux işletim sistemi üzerinde bir user oluşturulur ve hadoop grubuna eklenir.

```
[yyukselveysel44@masternode01 ~]$ sudo useradd sampleuser1 -G hadoop
```

```
[yyukselveysel44@masternode01 ~]$ sudo su -
```

```
hadoop
```

```
Last login: Sun Sep 8 13:10:26 UTC 2024 on pts/0
```

Daha sonra HDFS dizininde user ile aynı isimde /user/<username> olacak şekilde bir directory oluşturulur ve izin-sahipliği yeni oluşturulan user olarak ayarlanır.

```
[hadoop@masternode01 ~]$ hdfs dfs -mkdir -p /user/sampleuser1
```

```
[hadoop@masternode01 ~]$ hdfs dfs -chown sampleuser1:hadoop
```

```
/user/sampleuser1
```

```
[hadoop@masternode01 ~]$ hdfs dfs -chmod 755 /user/sampleuser1
```

HDFS User Oluşturma

HDFS komutlarının kullanımı için bashrc dosyasında yer alan .env değişkenlerini sampleuser1'in bashrc dosyasına da kopyalamak gerekir.

İşletim sistemine sampleuser1 ile login olunduktan sonra bir txt dosyası oluşturulur ve ilgili dizine kopyalanır. Dosya kopyalanırken destination dizin verilmediğinde o dosya HDFS'te ilgili user'ın home dizinine yani bu örnek için /user/sampleuser1 dizinine kopyalayacaktır.

```
[sampleuser1@masternode01 ~]$ touch newsamplefile.txt
```

```
[sampleuser1@masternode01 ~]$ hdfs dfs -put /home/sampleuser1/newsamplefile.txt
```

```
[sampleuser1@masternode01 ~]$ hdfs dfs -ls
```

Found 1 items

```
-rw-r--r-- 1 sampleuser1 hadoop    0 2024-09-08 13:23 newsamplefile.txt
```

```
[sampleuser1@masternode01 ~]$ hdfs dfs -ls /user/sampleuser1
```

Found 1 items

```
-rw-r--r-- 1 sampleuser1 hadoop    0 2024-09-08 13:23 /user/sampleuser1/newsamplefile.txt
```

HDFS Dosya-Dizin Yetkileri



HDFS, dosya ve dizinler için üç temel izin türü sunar:

- Okuma İzni (r): Dosyanın içeriğini okuma izni.
- Yazma İzni (w): Dosyanın içeriğini değiştirme veya dosyayı silme izni.
- Yürütme İzni (x): Dizini listeleme ve içine erişme izni.

İzinler genellikle rwx formatında belirtilir ve her bir izin 3 basamaktan oluşur:

- İlk Basamak: Kullanıcı izinleri (owner permissions).
- İkinci Basamak: Grup izinleri (group permissions).
- Üçüncü Basamak: Diğer kullanıcılar için izinler (others permissions).

Örneğin, rwxr-xr-- izni şu şekilde okunur:

rwx : Dosya sahibi (user) için okuma, yazma ve yürütme izinleri.

r-x : Grup üyeleri (group) için okuma ve yürütme izinleri.

r-- : Diğer kullanıcılar (others) için sadece okuma izni.

HDFS Dosya-Dizin Yetkileri



Bu izinlerin herbirinin sayısal bir değer karşılığı vardır. Read 4, write 2 ve Execute 1 'dir. Üçlü basamak halinde izin grupları oluşturulduğundan örneğin bir dosyaya tüm user'lar için rwx hakkı vermek için 777 izin hakkı verilmesi gerekir.

Chmod Calculator

An awesome Chmod Calculator to convert Linux file permissions between different formats.

Owner

Read ☒

Write ☒

Execute ☒

Group

Read ☒

Write ☒

Execute ☐

Public

Read ☒

Write ☐

Execute ☐

Linux

Permissions:

764

rwxrw-r--



HDFS Trash

Trash, Çöp kutusu HDFS'te silinen bir dosya veya dizinin geri alınabilmesine olanak sağlayan mekanizmadır. Bir dosya veya dizin silindiğinde, veriler doğrudan kalıcı olarak silinmez. Bunun yerine, silinen veriler trash dizinine taşınır. Kullanıcı bu verileri daha sonra geri alabilir veya kalıcı olarak silebilir.

Tras dizinin yolu her user için kendi home directory'sinin altıdır.

`/user/<username>/.Trash/`


Core-site.xml

```
<property>
<name>fs.trash.interval</name>
<value>360</value>
</property>
```





Resource Manager Web UI

- **Vcore ve vmemory** kavramları yarn'ın kaynak yönetimi sırasında fiziksel kaynaklar için oluşturduğu sanal iz düşümleridir. Bazı durumlarda fiziksel bir kaynak virtual birden çok kaynak tarafından kullanılabilir.
 - **Cluster Nodes metrics alanında**, nodemanager'larla alakalı metrikler yer alır. Clusterde şu anda active 2 node manager vardır. Nodemanager servislerinde bir sorun olduğunda lost nodes veya unhealthy node sayıları sıfırdan farklı olur.
 - **Scheduler metrics** alanında kaynakların yönetimi ile ilgili metrikler görülür. Şu anda capacity scheduler kullanılmaktaydı. Oluşturulan farklı kuyruklar ve özellikleri de bu alanda görüntülenebilir.
 - **En altta Cluster overview** alanında ise ClusterID, resource manager'ın statusu, Resource manager'ın başlatılma saati ve versiyonu, hadoop cluster'ın versiyonu gibi bilgiler yer almaktadır.
- 

HDFS Trash

Trash enable durumda iken Bir dosya silindiğinde aşağıdaki gibi, dosyanın çöp kutusuna atıldığına dair bir uyarı gösterilir.

```
[sampleuser1@masternode01 ~]$ hdfs dfs -rm -r newsamplefile.txt
2024-09-08 14:10:32,667 INFO fs.TrashPolicyDefault: Moved:
'hdfs://masternode01:9000/user/sampleuser1/newsamplefile.txt' to trash at:
hdfs://masternode01:9000/user/sampleuser1/.Trash/Current/user/sampleuser1/newsamplefile.txt
```

Çöp kutusundan bu dosyayı mv komutu ile geri getirmek için;

```
[sampleuser1@masternode01 ~]$ hdfs dfs -ls
Found 1 items
drwx----- - sampleuser1 hadoop    0 2024-09-08 14:10 .Trash
[sampleuser1@masternode01 ~]$ hdfs dfs -mv
/user/sampleuser1/.Trash/Current/user/sampleuser1/newsamplefile.txt newsamplefile.txt
[sampleuser1@masternode01 ~]$ hdfs dfs -ls
Found 2 items
drwx----- - sampleuser1 hadoop    0 2024-09-08 14:10 .Trash
-rw-r--r--  1 sampleuser1 hadoop    0 2024-09-08 14:10 newsamplefile.txt
```

Çöp kutusu da hdfs dfs -rm -r /user/<username>/.Trash komutu ile boşaltılabilir.

YARN Container

Bir container, belirli miktarda kaynak tahsis etmiş ve bir işin çalıştırılabilir bir ortamını temsil eden sanal bir birimdir. YARN'da işlerin izole bir şekilde çalıştırılmasını sağlar.

Container'ın çalışma adımları şunlardır;

1. Uygulama İsteği: Bir uygulama çalıştırmak için, uygulama belirli bir kaynak talebi (bellek, CPU) ile ResourceManager'a başvurur.
2. Kaynak Tahsisi: ResourceManager, bu talebi alır ve uygun kaynakları tahsis edebilecek bir NodeManager bulur. NodeManager, uygun container'ı oluşturur ve gerekli kaynakları tahsis eder.
3. Container Başlatma: NodeManager, tahsis edilen kaynaklarla container'ı başlatır. Container içerisinde uygulamanın iş yükü çalıştırılır.
4. Kapsayıcı Yönetimi: Uygulamanın çalışması sırasında container, kaynak kullanımını izler ve yönetir. Uygulama tamamlandığında, container kapanır ve kaynaklar serbest bırakılır.

HDFS Replication



HDFS'te replication veriyi güvence altına almak ve high availability'i sağlamak için kullanılır. Replication sayesinde bir dosyanın birden çok dosyası farklı node'larda saklanır. Bir dosyanın oluşturulan her bir kopyasına "replica" denir. Replicalar, HDFS'de farklı veri düğümlerinde saklanır. Replication faktör değeri ile bir dosya'nın clusterda kaç kopyasının saklanacağı belirlenir.

Okuma İşlemi: Verilere erişim sırasında, HDFS uygun bir replica'dan veri okur. HDFS, genellikle en yakın veya en hızlı replica'yı seçmeye çalışır.

Yazma İşlemi: Dosya yazılırken, HDFS ilk olarak verileri bir replica'ya yazar ve ardından kopyaları diğer düğümlere dağıtır.

Cluster seviyesinde replication factor'ü ayarlamak için core-site.xml dosyası içinde aşağıdaki parametre set edilmelidir.

```
<property>  
<name>dfs.replication</name>  
<value>2</value>  
</property>
```





HDFS Replication

HDFS üzerinde yer alan bir dosyanın replication faktör değeri o dosyaya özel olacak şekilde değiştirilebilir. Örneğin Cluster seviyesinde replication faktör parametresi 2 olarak ayarlanmışken, belirli bir dosyanın replica sayısı 5 olarak ayarlanabilir. Bunu gerçekleştirebilmek için de `hdfs dfs -setrep -w 5 /path/to/file` komutu kullanılır.

`hdfs dfs -stat %r /path/to/file` komutu ile dosya için geçerli olan replication factor parametresi görüntülenebilir.

```
[hadoop@masternode01 hadoop]$ hdfs dfs -ls /input
Found 3 items
-rwxrwxrwx 1 hadoopnew hadoopnew    83 2024-09-04 20:01 /input/example2.txt
-rw-r--r-- 1 hadoop supergroup   69 2024-09-02 20:48 /input/input.txt
-rw-r--r-- 1 hadoop supergroup    0 2024-09-08 11:02 /input/newsamplefile
[hadoop@masternode01 hadoop]$ hdfs dfs -stat %r /input/newsamplefile
1
[hadoop@masternode01 hadoop]$ hdfs dfs -setrep -w 2 /input/newsamplefile
Replication 2 set: /input/newsamplefile
Waiting for /input/newsamplefile ... done
[hadoop@masternode01 hadoop]$ hdfs dfs -stat %r
/input/newsamplefile
2
```





HDFS Replication

dfs.replication.max : Dosyaların maksimum kaç replikasının olabileceğine dair sınır belirler. Genellikle büyük bir değer belirlenir.

dfs.replication.min : Dosyaların minimum kaç replikasının olabileceğini belirler.

dfs.namenode.replication.interval : NameNode'un ne sıklıkla replicaların statülerini kontrol edeceğini belirler. Bu parametreye verilen aralıklarla NN replicaların sağlıklı olup olmadığını kontrol eder. Saniye cinsinden ayarlanır, default 300'dür

dfs.replication.user : Belirli bir user için replication factor ayarlanmasını sağlar



HDFS FSCK



- hdfs fsck komutu, HDFS'teki dosya ve blokların durumunu kontrol etmek için kullanılır. Dosyaların ve blokların sağlık durumu, eksik veya hatalı bloklar, replikaların durumu gibi bilgilerin görülmesini sağlar.
-
- [hadoop@masternode01 ~]\$ hdfs fsck /user/sampleuser1/newsamplefile.txt -files -blocks -locations

Status: HEALTHY

Number of data-nodes: 2

Number of racks: 1

Total dirs: 0

Total symlinks: 0

Replicated Blocks:

Total size: 0 B

Total files: 1

Total blocks (validated): 0

Minimally replicated blocks: 0

Over-replicated blocks: 0

Under-replicated blocks: 0

Mis-replicated blocks: 0

Default replication factor: 1

Average block replication: 0.0

Missing blocks: 0

Corrupt blocks: 0

Missing replicas: 0

Blocks queued for replication: 0

Erasure Coded Block Groups:

Total size: 0 B

Total files: 0

Total block groups (validated): 0

Minimally erasure-coded block groups: 0

Over-erasure-coded block groups: 0

Under-erasure-coded block groups: 0

Unsatisfactory placement block groups: 0

Average block group size: 0.0

Missing block groups: 0

Corrupt block groups: 0

Missing internal blocks: 0

HDFS dfs stat



hdfs dfs -stat komutu, dosya ve dizinler hakkında çeşitli bilgilerin görüntülenmesini sağlar. Bu komut, dosya veya dizinlerin özelliklerini raporlamak için kullanılır ve genellikle belirli bilgileri (örneğin dosya boyutu, oluşturulma tarihi) almak için kullanılır.

hdfs dfs -stat <format-string> <path>

%b: Dosyanın boyutu (bayt cinsinden).

%n: Dosyanın adı.

%p: Dosyanın tam yolu.

%t: Dosyanın son değişiklik tarih ve saati.

%u: Dosyanın sahibi.

%g: Dosyanın grubu.

%r: Dosyanın replication faktörü.

%a: Dosyanın erişim izni (permissions).

```
[hadoop@masternode01 ~]$ hdfs dfs -stat %a /user/sampleuser1/newsamplefile.txt
```

```
644
```

```
[hadoop@masternode01 ~]$ hdfs dfs -stat "%u %g" /user/sampleuser1/newsamplefile.txt  
sampleuser1 hadoop
```

HDFS dfsadmin report

HDFS'in genel durum raporunu görüntülemek için kullanılır. Bu komut, HDFS'in datanode'ları ve genel dosya sistemi durumu hakkında önemli bilgiler sağlar. Bu rapor sonucu görülebilecek bazı bilgiler;

- Genel Sistem Bilgileri
 - HDFS Kullanılabilir Alan: HDFS'in toplam, kullanılabilir ve kullanılan alan miktarı.
 - Toplam Blok Sayısı: HDFS'deki toplam blok sayısı.
- Datanode'lar Hakkında Bilgiler
 - DataNode Hostnames: Her bir DataNode'un ana makine adı ve IP adresi.
 - Düğüm Durumu: Her bir DataNode'un durumu (sağlıklı, uykuda, vb.).
 - Kullanılabilir Alan: Her bir DataNode üzerindeki kullanılabilir alan.
 - Toplam Alan: Her bir DataNode üzerindeki toplam alan.
 - Kullanılan Alan: Her bir DataNode üzerindeki kullanılan alan.
 - Blok Sayısı: Her bir DataNode üzerindeki blok sayısı.
 - Replikasyon Bilgileri: DataNode üzerindeki veri bloklarının replikasyon durumu.
- Blok ve Replikasyon Bilgileri
 - Eksik Bloklar: HDFS'de bulunan eksik bloklar hakkında bilgi.
 - Yetersiz Replikalar: Replikasyon faktörü altında kalan bloklar hakkında bilgi.
 - Aşırı Replikalar: Replikasyon faktöründen fazla kopyası olan bloklar hakkında bilgi.

HDFS NN WebUI

Hadoop NN Webui ile de cluster hakkında birçok bilgi edinilebilir.

Hadoop

Overview

Datanodes

Datanode Volume Failures

Snapshot

Startup Progress

Utilities

Overview

'masternode01:9000' (✓active)

Started:	Sun Sep 08 21:33:57 +0300 2024
Version:	3.4.0, rbd8b77f398f626bb7791783192ee7a5dfaee760
Compiled:	Mon Mar 04 09:35:00 +0300 2024 by root from (HEAD detached at release-3.4.0-RC3)
Cluster ID:	CID-278c890d-000e-4ea7-99a8-74ddcf8b56d5
Block Pool ID:	BP-1338227746-10.128.0.8-1725307935256

Summary

Security is off.

Safemode is off.

77 files and directories, 45 blocks (45 replicated blocks, 0 erasure coded block groups) = 122 total filesystem object(s).



Heap Memory used 94.29 MB of 374 MB Heap Memory. Max Heap Memory is 1.67 GB.

Non Heap Memory used 77.11 MB of 78.84 MB Committed Non Heap Memory. Max Non Heap Memory is <unbounded>.

Configured Capacity:	39.59 GB
----------------------	----------

HDFS Snapshot

HDFS'de snapshot özelliđi sayesinde bir dosya veya dizinin anlık görüntüsü alınabilir. Snapshotlar ile dosyanın eski haline döndürölmesine olanak sağlanır. Bu sayede veri kaybının da önüne geçilebilir. Genellikle yedekleme, kurtarma ve veri yönetimi gibi amaçlarla kullanılır. Verinin kopyasını deđil, metadata bilgisi üzerinden bu işlemi gerçekleştirir. Yine de disk üzerinde ekstra maliyete sebep olur.



HDFS Snapshot

Snapshot almak için aşağıdaki komut uygulanır.

```
hdfs dfsadmin -createSnapshot <snapshot-alınacak-dizin-dosya> <snapshot-name>
```

Snapshotları listelemek için aşağıdaki komut uygulanır.

```
hdfs dfs -lsSnapShot <snapshot-dir>
```

Belirli bir snapshot içeriğini görüntülemek için:

```
hdfs dfs -ls <snapshot-dir>/.snapshot/<snapshot-name>
```

Snapshot'ı silmek için;

```
hdfs dfsadmin -deleteSnapshot <snapshot-dir> <snapshot-name>
```

Snapshot'a geri dönmek için de snapshot dizinindeki dosya, mevcut dizine kopyalanır

```
hdfs dfs -cp /user/hadoop/mydir/.snapshot/my_snapshot/somefile  
/user/hadoop/mydir/
```



Dfsadmin allowsnapshot komutu ile bir directory'nin snap'inin alınmasına izin verilir.

```
[hadoop@masternode01 ~]$ hdfs dfsadmin -allowSnapshot /input
```

```
Allowing snapshot on /input succeeded
```

```
[hadoop@masternode01 ~]$ hdfs dfs -createSnapshot /input sample-snapshot
```

```
Created snapshot /input/.snapshot/sample-snapshot
```



HDFS Rebalance

HDFS rebalance, HDFS üzerindeki veri bloklarının nodelar arasında dengeli bir şekilde dağılmasını sağlar. Böylece node'lar üzerindeki dengesizlikler giderilerek cluster daha dengeli bir hal alır ve daha yüksek performans ile çalışır. Özellikle veri ekleme, silme veya cluster'a node eklendiğinde veri bloklarının düzensiz bir şekilde dağılması durumunda kullanılır.



Balancer ilk olarak data'nın node'lar arasında dağılımını inceler, sonra node'lar arasında veri taşıma işlemini tamamlar.

```
hdfs balancer -threshold <threshold_value>
```

Threshold değeri blokların ne kadar dengesiz olabileceğini belirleyen bir eşik değeridir.



Herhangi bir threshold değerine bakılmaksızın balancer'u çalıştırmak için

hdfs balancer komutu çalıştırılır.



HDFS Rebalance

```
[hadoop@masternode01 ~]$ start-all.sh
WARNING: Attempting to start all Apache Hadoop daemons as hadoop in 10 seconds.
WARNING: This is not a recommended production deployment configuration.
WARNING: Use CTRL-C to abort.
Starting namenodes on [masternode01]
Starting datanodes
slavenode02: Warning: Permanently added the ECDSA host key for IP address '34.136.172.31' to the list of known hosts.
slavenode01: Warning: Permanently added the ECDSA host key for IP address '34.29.20.161' to the list of known hosts.
Starting secondary namenodes [masternode01]
Starting resourcemanager
Starting nodemanagers
[hadoop@masternode01 ~]$ hdfs balancer
2024-09-09 18:28:10,923 INFO impl.MetricsConfig: Loaded properties from hadoop-metrics2.properties
2024-09-09 18:28:11,087 INFO impl.MetricsSystemImpl: Scheduled Metric snapshot period at 10 second(s).
2024-09-09 18:28:11,087 INFO impl.MetricsSystemImpl: Balancer metrics system started
2024-09-09 18:28:11,140 INFO balancer.Balancer: namenodes = [hdfs://masternode01:9000]
2024-09-09 18:28:11,140 INFO balancer.Balancer: parameters = Balancer.BalancerParameters [BalancingPolicy.Node, threshold = 10.0, max idle it
ded nodes = 0, #source nodes = 0, #blockpools = 0, run during upgrade = false, sort top nodes = false, hot block time interval = 0]
2024-09-09 18:28:11,141 INFO balancer.Balancer: included nodes = []
2024-09-09 18:28:11,141 INFO balancer.Balancer: excluded nodes = []
2024-09-09 18:28:11,141 INFO balancer.Balancer: source nodes = []
Time Stamp      Iteration#  Bytes Already Moved  Bytes Left To Move  Bytes Being Moved  NameNode
2024-09-09 18:28:11,146 INFO balancer.NameNodeConnector: getBlocks calls for hdfs://masternode01:9000 will be rate-limited to 20 per second
2024-09-09 18:28:12,886 INFO balancer.Balancer: dfs.namenode.get-blocks.max-qps = 20 (default=20)
2024-09-09 18:28:12,886 INFO balancer.Balancer: dfs.balancer.movedWinWidth = 5400000 (default=5400000)
2024-09-09 18:28:12,886 INFO balancer.Balancer: dfs.balancer.moverThreads = 1000 (default=1000)
2024-09-09 18:28:12,886 INFO balancer.Balancer: dfs.balancer.dispatcherThreads = 200 (default=200)
2024-09-09 18:28:12,886 INFO balancer.Balancer: dfs.balancer.getBlocks.size = 2147483648 (default=2147483648)
2024-09-09 18:28:12,886 INFO balancer.Balancer: dfs.balancer.getBlocks.min-block-size = 10485760 (default=10485760)
2024-09-09 18:28:12,887 INFO balancer.Balancer: dfs.datanode.balance.max.concurrent.moves = 100 (default=100)
2024-09-09 18:28:12,887 INFO balancer.Balancer: dfs.datanode.balance.bandwidthPerSec = 104857600 (default=104857600)
2024-09-09 18:28:12,896 INFO balancer.Balancer: dfs.balancer.max-size-to-move = 10737418240 (default=10737418240)
2024-09-09 18:28:12,896 INFO balancer.Balancer: dfs.blocksize = 134217728 (default=134217728)
2024-09-09 18:28:12,936 INFO net.NetworkTopology: Adding a new node: /default-rack/34.29.20.161:9866
2024-09-09 18:28:12,936 INFO net.NetworkTopology: Adding a new node: /default-rack/34.136.172.31:9866
2024-09-09 18:28:12,939 INFO balancer.Balancer: 0 over-utilized: []
2024-09-09 18:28:12,939 INFO balancer.Balancer: 0 underutilized: []
Sep 9, 2024 6:28:12 PM      0      0 B      0 B      0 B      0 hdfs://masternode01:9000
The cluster is balanced. Exiting...
Sep 9, 2024 6:28:13 PM  Balancing took 3.128 seconds
```



Soru-Cevap

